

Intelligent System for Portfolio Selection

A. H. C. Silva and W. S. Lacerda

Abstract— The aim of this paper was to develop an intelligent system for portfolio selection that assists the investor in selecting assets for the composition of an optimal portfolio of investments. It was built a variation of the Markowitz Model, where the forecast price is reported by a predictor, using the Support Vector Machines (SVM) technique. The SVMs obtained an average prediction error of 7.13% and a standard deviation of 2.88%, which shows that most of SVMs performed good predictions about the data set.

Keywords— portfolio selection, markowitz model, forecasting financial series, support vector machines.

I. INTRODUÇÃO

O MERCADO financeiro reúne pessoas e organizações que precisam de dinheiro (agentes deficitários) com aqueles que têm recursos excedentes (agentes superavitários). Existem vários mercados financeiros em uma economia desenvolvida [1].

Um dos principais tipos de mercado é o Mercado de capitais, onde são realizadas operações financeiras de compra e venda de ações e valores mobiliários. As transações e negociações que ocorrem durante as operações financeiras acontecem por meio do Mercado de ações (que faz parte do Mercado de capitais).

Investir em ativos de renda variável no mercado financeiro não é uma tarefa simples. Devido à sua alta instabilidade, as operações realizadas apresentam alta volatilidade, expondo os investidores ao risco. Não há um retorno garantido do investimento e existe, também, a possibilidade de perda do valor investido.

Muitos profissionais buscam ferramentas para previsão de tendências do mercado como forma de tentar gerenciar o risco. Dentre estas ferramentas, destacam-se as técnicas de Inteligência Computacional, principalmente Redes Neurais Artificiais (RNA), para previsão de séries temporais financeiras.

Além de tentar prever o mercado, todo investidor também procura um modo para otimizar seus investimentos. Uma das maneiras de minimizar o risco consiste na diversificação de investimentos através da formação de carteiras de investimentos.

Ao aplicar recursos em ações de apenas uma empresa ou em empresas de um setor econômico específico, o risco de perda pode ser muito alto. Com a diversificação, isto é, a aplicação de recursos em papéis de setores econômicos diferentes, o risco é menor, pois se um determinado setor A estiver em queda e um outro setor B estiver em alta, o prejuízo

obtido pela queda no setor A pode ser compensado pela rentabilidade alcançada no setor B .

Os estudos relacionados à diversificação e otimização de investimentos iniciaram-se com Markowitz [2]. Ele utilizou a variância da rentabilidade dos ativos como medida de risco e a usou agregado a estimativas de retorno dos ativos para seleção de carteiras, estruturando a base da Teoria Moderna de Seleção de Carteiras [3]. A partir dessa teoria, ele pôde demonstrar como a compra de diferentes ativos influencia na diminuição dos riscos de uma carteira.

No trabalho de Freitas *et al.* [4] foi apresentada uma versão modificada do Modelo de Markowitz, que utiliza predição de séries temporais, aplicando RNA para previsão dos preços futuros. Esse modelo modificado alcançou retornos maiores que o modelo padrão de Markowitz (modelo de média-variância).

O objetivo deste artigo é apresentar um sistema inteligente, baseado em uma variação do Modelo de Markowitz, onde a previsão dos preços de fechamento futuros será informada a partir de um preditor, utilizando a técnica Máquina de Vetores de Suporte (MVS) [5, 6, 7]. Desta forma, o sistema auxiliará investidores na escolha de ativos para a composição de carteiras ótimas de investimentos, de modo que as carteiras sugeridas ao investidor tenham um risco mínimo e sejam rentáveis.

O presente artigo está organizado da seguinte forma. Na seção II, são descritos a Teoria Moderna de Carteiras, o modelo proposto por Markowitz e fronteira eficiente. Materiais e métodos são relatados na seção III, apresentando as ferramentas, métricas utilizadas, resolução do problema de Markowitz e os procedimentos metodológicos, desde a construção do *parser* para tratamento do arquivo de dados até o treinamento e validação da técnica MVS. Resultados e o sistema desenvolvido são apresentados na seção IV. E, por fim, conclusão e trabalhos futuros são descritos na seção V.

II. TEORIA MODERNA DAS CARTEIRAS

A maioria das pessoas que investem no mercado financeiro certamente possuem uma carteira de investimentos. Esta, provavelmente, é composta por ativos *reais* ou *financeiros*. Ativos *reais* podem ser imóveis, empresas, veículos automotivos, ouro e ativos *financeiros* são ações, *commodities*, debêntures, taxas de juros e títulos de renda fixa [8].

A seleção de uma carteira de investimentos está intimamente ligada a dois fatores de extrema importância que são *risco* e *retorno*. Para escolher uma carteira ótima de investimentos, faz-se necessário encontrar um conjunto de ativos que atendam aos objetivos dos investidores.

Desta forma, caso o investidor tenha um perfil ousado, ele poderá aplicar seus investimentos em ativos com uma maior taxa de retorno, principalmente a curto prazo. Por outro lado,

A. H. C. Silva, Universidade Federal de Minas Gerais (UFMG), Belo Horizonte, Minas Gerais, Brasil, andrecosta@dcc.ufmg.br.

W. S. Lacerda, Universidade Federal de Lavras (UFLA), Lavras, Minas Gerais, Brasil, lacerda@prpg.ufla.br.

se o investidor tiver o perfil cauteloso, terá como foco aplicar seus investimentos em ativos que apresentem riscos menores e acumulem um retorno positivo considerável a longo prazo.

A. Início da Teoria Moderna de Carteiras

O pioneiro da Teoria Moderna de Carteiras (TMC) foi o economista americano Harry Markowitz, que iniciou estudos relacionados à diversificação e otimização de carteira de investimentos [2]. Foi utilizando a média variância da rentabilidade dos ativos como medida de risco e, posteriormente, usando-as em conjunto com as estimativas de retorno dos ativos para seleção de carteiras que ele estruturou a TMC [3].

Portanto, o modelo proposto por Markowitz [2] é comumente conhecido como modelo de Média-Variância, pois usa o retorno esperado médio como medida de desempenho da carteira e a variância como medida de risco [3]. Este modelo consiste na diversificação de investimentos, de modo que os riscos que o investidor deseja assumir sejam minimizados e que os retornos esperados sejam maximizados.

B. O Modelo de Markowitz para Seleção de Carteiras

De acordo com o modelo apresentado por Markowitz [2], o retorno esperado de uma determinada carteira pode ser definido como a média ponderada dos retornos esperados dos ativos com os respectivos pesos para cada ativo, conforme a Equação (1):

$$R_c = \sum_{i=1}^M X_i R_i, \quad (1)$$

onde R_c é o retorno esperado da carteira, M é o número de ativos presentes na carteira, X_i é o percentual a ser investido no ativo i e R_i é o retorno esperado do ativo i .

O risco (ou variância do retorno) de uma determinada carteira consiste em calcular a variância dos retornos dos ativos que formam a carteira de investimentos, como indicado na Equação (2):

$$V = \sum_{i=1}^M \sum_{j=1}^M X_i X_j \sigma_{ij}, \quad (2)$$

onde V é o risco da carteira, X_i (X_j) é o percentual a ser investido no ativo i (j) e σ_{ij} é a covariância entre os pares de ativos i e j .

Freitas *et al.* [4] apresentaram uma formulação do Modelo de Markowitz [2] que possibilita minimizar o risco de uma determinada carteira. No presente trabalho, a minimização do risco da carteira foi formulada através da Equação (3):

$$\text{minimizar } V = \sum_{i=1}^M \sum_{j=1}^M X_i X_j \sigma_{ij}, \quad (3)$$

sujeito às seguintes restrições:

$$\sum_{i=1}^M X_i R_i = R_c, \quad (4)$$

$$\sum_{i=1}^M X_i = 1, \quad (5)$$

$$X_i \geq 0, \quad i = 1, \dots, M. \quad (6)$$

A Equação (4) é a restrição de retorno desejado, Equação (5) garante total alocação dos recursos e Equação (6) limita o modelo, permitindo apenas efetuar operações de compra.

C. Fronteira Eficiente

A *fronteira eficiente* pode ser considerada como um conjunto de carteiras que satisfazem as Equações (4), (5) e (6). Cada carteira presente nesta fronteira pode ser considerada uma *carteira eficiente*, pois esta possui o maior retorno para um certo nível de risco, se comparada às outras carteiras presentes na fronteira. Assim, o investidor deve optar pela melhor carteira, isto é, a que melhor atende ao seu perfil e que esteja presente na *fronteira eficiente*.




Figura 1. Fronteira Eficiente.

Como pode ser observado na Fig. 1, os pontos 1, 3, 5 e 8 estão na fronteira eficiente e os pontos 2, 4, 6 e 7 são carteiras ineficientes, pois não estão na fronteira. O investidor ousado poderia escolher a carteira eficiente que está no ponto 5, pois é a que apresenta maior retorno dentro da fronteira eficiente. Por outro lado, o investidor cauteloso talvez escolheria a carteira eficiente do ponto 3, onde o risco e retorno esperado podem ser considerados baixos se comparados aos dos demais pontos.

Considerando a carteira do ponto 3, percebe-se que não há nenhuma outra carteira que tenha o mesmo retorno com um risco menor. O ponto 6, por exemplo, apresenta um retorno um pouco maior que 3, porém seu risco é consideravelmente maior.

É importante destacar que há uma forte relação entre o retorno esperado e o risco. Quanto maior o risco a ser assumido, maior o retorno esperado que pode ser alcançado; analogamente, quanto menor o risco, menor o retorno esperado.

III. MATERIAIS E MÉTODOS

Nesta seção são apresentadas ferramentas e métricas utilizadas para a implementação e desenvolvimento do sistema

proposto neste artigo. O processo de coleta de dados também é descrito. São enunciados os procedimentos, desde a construção do *parser* para tratamento do arquivo de dados até o treinamento e validação da técnica MVS e a execução de seu teste. E, por fim, é descrito o processo de minimização do risco.

A. Ferramentas Utilizadas

Para a implementação da técnica MVS e a construção do sistema, utilizou-se o ambiente de desenvolvimento Eclipse (versão *Juno*) e a linguagem de programação Java (software JDK versão 1.7.0).

As Máquinas de Vetores de Suporte (MVSs) foram implementadas por meio do *framework* LIBSVM (versão 3.17), desenvolvido por Hsu *et al.* [9].

O *framework* JOptimizer foi utilizado para a resolução do problema de minimização do risco, apresentado nas Equações (3), (4), (5) e (6).

B. Coleta de Dados

Os dados necessários para a realização dos treinamentos, validações e testes foram coletados no site da BM&FBOVESPA, onde estão disponibilizados arquivos referentes às informações das cotações históricas relativas à negociação de todos os papéis no período de um ano. Foi escolhida a base de dados relativa ao período de Janeiro a Dezembro de 2012. Limitou-se a considerar somente os 71 papéis presentes no IBOVESPA.

O arquivo de cotações históricas disponibilizado tem o formato *txt* e vêm com o nome *COTAHIST.AAAA.txt*, sendo que *AAAA* identifica o ano das cotações. Por exemplo: *COTAHIST.1990.txt*, *COTAHIST.2000.txt*, *COTAHIST.2012.txt*, etc. Cada arquivo possui uma estrutura bem definida com diversas informações referentes às cotações.

C. Parser

O *parser* tem a tarefa de ler e selecionar as informações que são relevantes para o escopo do problema. Através dele, os dados presentes no arquivo de cotações históricas são processados e convertidos para um formato adequado.

Cada linha do arquivo de cotações históricas contém informações de um pregão referente a determinado papel no decorrer de um dia. Foram extraídas pelo *parser* as seguintes informações: data do pregão, código de negociação do papel, nome resumido da empresa emissora do papel e preço do último negócio do papel-mercado (preço de fechamento) no pregão.

O processo de extração ocorreu de acordo com a estrutura do arquivo, definida pela BM&FBOVESPA e representada na Tabela I, que mostra como localizar na linha as informações desejadas. Na Tabela I, os dois últimos caracteres do Preço de Fechamento (120 e 121) se referem às casas decimais.

TABELA I. ESTRUTURA DO ARQUIVO DE COTAÇÕES HISTÓRICAS.

Nome do Campo	Tipo	Posição Inicial	Posição Final
Data do Pregão	Númerico	3	10
Código do Papel	Literal	13	24
Nome da Empresa	Literal	28	39
Preço de Fechamento*	Númerico	109	121

Após extrair as informações do arquivo de cotações históricas, o *parser* cria uma nova estrutura que facilita manusear os dados internamente no sistema. Esta nova estrutura está representada na Fig. 2. Com isso, cada papel terá esta estrutura e o acesso aos pregões referentes a este papel se dará de uma forma mais simples, pois estarão armazenados em uma lista de pregões, ordenada de maneira crescente conforme a data de cada pregão.




Figura 2. Estrutura de Dados do Sistema.

D. Preparação e Normalização dos Dados

Para cada papel existe uma lista de pregões, sendo que cada pregão representa um dia de negociação, com seu respectivo preço de fechamento. Esta lista pode ser considerada como um conjunto de dados.

O conjunto de dados de cada papel foi dividido em três partes: treinamento (80% do conjunto de dados), validação (10%) e teste (10%). É através do conjunto de treinamento que a MVS é treinada, isto é, a partir do conjunto de treinamento que um modelo é criado. O conjunto de validação não faz parte do conjunto de treinamento e é utilizado para verificar o desempenho da MVS durante o treinamento e evitar *overfitting*. E o conjunto de teste serve para avaliar o desempenho do modelo criado após o treinamento.

Por meio da normalização dos dados, é possível evitar que atributos em intervalos numéricos maiores dominem aqueles que estão em intervalos numéricos menores, influenciando na capacidade de generalização da técnica descrita. Portanto, os preços de fechamento presentes no conjunto de dados de cada papel passaram por um processo de normalização, conforme a Equação (7), no intervalo entre 0 e 1, antes de serem apresentados às suas respectivas MVS. Na Equação (7), x é o preço de fechamento, min é o menor preço de fechamento e max o maior preço de fechamento do conjunto de dados. A Fig. 3 mostra um exemplo com os preços de fechamento normalizados.

$$x_{norm} = \frac{x - min}{max - min} \quad (7)$$



Figura 3. Exemplo de conjuntos de dados normalizado no intervalo entre 0 e 1.

E. Técnica de Janelamento

Os dados de entrada e saída foram organizados utilizando a técnica de janelamento. Considerando uma janela de tamanho igual a cinco, os valores de entrada são os cinco preços de fechamento históricos $P(t-4)$, $P(t-3)$, $P(t-2)$, $P(t-1)$, $P(t)$ e a saída é o preço futuro $P(t+1)$, isto é, o preço de fechamento do sexto dia. Logo, para uma janela de tamanho igual a dez, a saída será o preço de fechamento do décimo primeiro dia. Na Fig. 4 é exemplificado, de maneira simples, como funciona a técnica de janelamento.




Figura 4. Janela deslizante de tamanho igual a cinco.

Neste trabalho, foram realizados experimentos com janelas de tamanho igual a cinco, dez e quinze.

F. Métricas

Foram escolhidas para avaliar o desempenho da técnica MVS as seguintes métricas: raiz do erro médio quadrático (*root-mean squared error* - RMSE) e percentual do erro médio absoluto (*mean absolute percentage error* - MAPE).

A métrica RMSE consiste no cálculo da raiz quadrada do resultado obtido pela diferença entre os preços de fechamento estimados por um preditor e os preços de fechamento observados, como é mostrado na Equação (8),

$$RMSE = \sqrt{\frac{\sum_{t=1}^n (\hat{p}_t - p_t)^2}{n}}, \quad (8)$$

onde n é o número de instâncias (ou exemplos) de treinamento, \hat{p}_t é preço de fechamento estimado e p_t é o

preço de fechamento observado no tempo t . Através da métrica RMSE é possível avaliar a convergência do treinamento, sendo que o critério de parada é baseado no erro do conjunto de validação.

A métrica MAPE é normalmente expressa como porcentagem, utilizada amplamente na previsão de tendências, medindo a acurácia de um preditor baseado nos preços de fechamento observados e sendo, assim, importante para a avaliação da qualidade de predição da técnica utilizada. O MAPE pode ser obtido através da Equação (9).

$$MAPE = \frac{100\%}{n} \sum_{t=1}^n \sqrt{\left(\frac{p_t - \hat{p}_t}{p_t}\right)^2} \quad (9)$$

G. Arquitetura das MVSs

Foram implementadas 71 MVSs. O tipo de MVS escolhida foi SVR (*Support Vector Regression*), específica para problemas onde as saídas são contínuas (não discretas). O tipo de *kernel* escolhido foi o RBF (*Radial Basis Function*) *Kernel* e este possui dois parâmetros a serem definidos, empiricamente, pelo usuário, *custo* (C) e *gamma* (γ). Segue abaixo a função matemática da RBF:

$$K(x, y) = e^{-\gamma \|x - y\|^2} \quad (10)$$

No trabalho de Hsu *et al.* [9], eles mostraram que tentar sequências de crescimento exponencial para os valores dos parâmetros C e γ é um método prático para identificar bons parâmetros, isto é, parâmetros que fazem com que a MVS convirja. Logo, nos experimentos realizados durante a configuração das MVS, a escolha dos parâmetros C e γ foram baseadas neste método. Os valores para o parâmetro C variaram entre 2 e 2^9 e os valores para o parâmetro γ variaram entre 2^{-9} e 2^{-1} .

H. Processo de Construção da Carteira Ótima de Investimentos

Para o processo de construção da carteira ótima de investimentos, isto é, a carteira com o menor risco possível e com o retorno desejado pelo investidor (usuário), faz-se necessário, primeiramente, realizar o cálculo das séries de retornos dos papéis a serem considerados na carteira de investimentos. Ou seja, para cada dia de pregão de um determinado papel, teremos seu retorno calculado. Depois disso, é calculada a média aritmética das séries de retornos de cada papel. E, por fim, é calculada a covariância σ entre os papéis presentes na carteira, isto é, a covariância dos pares de ativos i e j .

Assim, após a formação da matriz de covariância, é possível minimizar o risco da carteira, onde a resposta será o percentual de alocação que se deve investir em cada papel considerado na carteira de investimentos.

A Fig. 5 apresenta um fluxograma mostrando como é realizada a integração das predições da técnica MVS com o modelo de Markowitz (modelo para minimização do risco de uma carteira) e, também, a interação com o usuário.

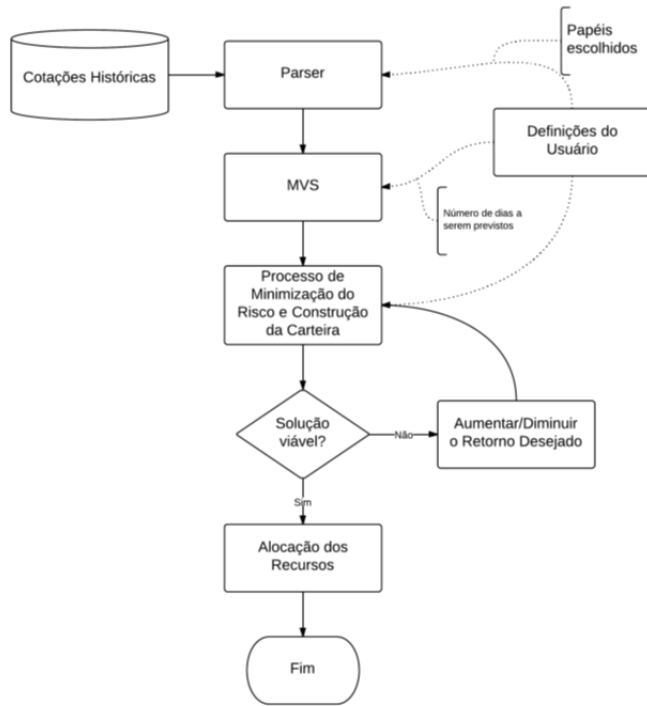


Figura 5. Fluxograma de Integração e Interação com o Usuário.

IV. RESULTADOS

Foram realizados diversos experimentos, com base nas amostras dos conjuntos de teste de cada papel, a fim de encontrar os melhores valores para os parâmetros para *custo* (C) e *gamma* (γ). Na Tabela II são apresentados os resultados obtidos pelos experimentos mais relevantes, com janela deslizante de tamanho igual a cinco.

TABELA II. RESULTADOS DOS EXPERIMENTOS REALIZADOS UTILIZANDO MVS COM JANELA DE TAMANHO IGUAL A CINCO.

Custo (C)	Gamma (γ)	RMSE (Média)	MAPE (Média)
2^9	2^{-9}	0,0476	0,0718
2^9	2^{-8}	0,0478	0,0721
2^9	2^{-7}	0,0481	0,0726
2^8	2^{-9}	0,0475	0,0715
2^7	2^{-9}	0,0474	0,0713
2^7	2^{-8}	0,0475	0,0714
2^6	2^{-9}	0,0482	0,0722
2^5	2^{-9}	0,0496	0,0735

Observando a Tabela II, o experimento com valores 2^7 e 2^9 para os parâmetros *custo* e *gamma*, respectivamente, foi o que obteve melhores resultados, sendo a média do MAPE igual a 7,13% e a média do RMSE igual a 4,74%.

Para efeito de esclarecimento, o valor RMSE (Média), apresentado na Tabela II, foi obtido por meio da seguinte equação

$$RMSE(Média) = \frac{1}{71} \sum_{i=1}^{71} RMSE(i), \quad (11)$$

onde 71 é a quantidade de MVSs (uma para cada papel considerado), $RMSE(i)$ é o erro RMSE obtido pela MVS i e $RMSE(Média)$ é a média aritmética dos erros obtidos pelas MVSs. O mesmo acontece para o valor $MAPE(Média)$,

$$MAPE(Média) = \frac{1}{71} \sum_{i=1}^{71} MAPE(i). \quad (12)$$

Com os melhores valores encontrados para os parâmetros *custo* (C) e *gamma* (γ), realizou-se novos experimentos, que são mostrados na Tabela III, alternando o tamanho da janela deslizante. Estes experimentos foram realizados com o objetivo de encontrar o melhor tamanho para janela deslizante. O experimento com janela de tamanho igual a cinco foi o que obteve os melhores resultados. Percebeu-se então que, conforme aumentava o tamanho da janela, o desempenho diminuía.

TABELA III. RESULTADOS DOS EXPERIMENTOS REALIZADOS UTILIZANDO MVS, ALTERNANDO O TAMANHO DA JANELA DESLIZANTE.

Tamanho da Janela	Custo (C)	Gamma (γ)	RMSE (Média)	MAPE (Média)
5	2^7	2^{-9}	0,0474	0,0713
10	2^7	2^{-9}	0,0494	0,0737
15	2^7	2^{-9}	0,0495	0,074

Os valores dos parâmetros para cada uma das MVSs implementadas são descritos a seguir:

- Tamanho da janela (entrada) = 5;
- Custo (C) = 2^7 ;
- *Gamma* (γ) = 2^9 ;
- Tipo de *kernel* = RBF *kernel*.

A Tabela IV mostra resultados mais detalhados quanto ao desempenho das 71 MVSs configuradas com os parâmetros descritos acima.

TABELA IV. DESEMPENHO DAS 71 MVSS MEDIANTE AS MÉTRICAS RMSE E MAPE.

Erro	Mínimo	Máximo	Média	Desvio Padrão
RMSE	0,0105	0,0709	0,0474	0,0118
MAPE	0,0085	0,1962	0,0713	0,0288

Através da Tabela IV, considerando as 71 MVSs implementadas, estas tiveram um erro de previsão médio de 7,13% e desvio padrão de 2,88%, o que mostra que a maioria das MVSs realizaram boas previsões sobre o conjunto de dados.

Como exemplo, na Fig. 6 está representado graficamente o desempenho da MVS quanto à sua capacidade de previsão para o papel PETR4.

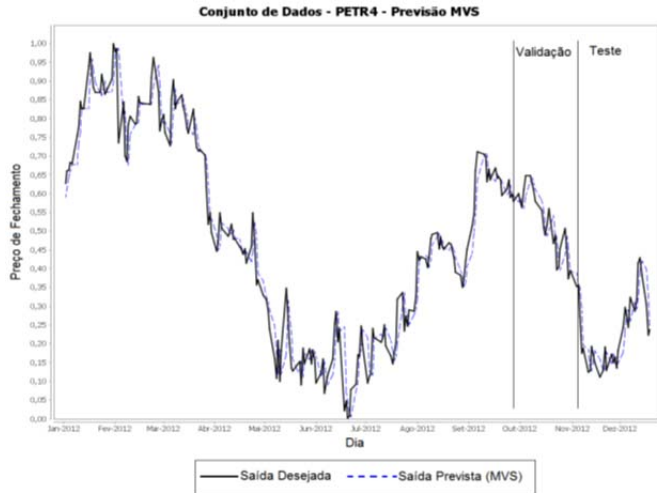


Figura 6. Desempenho da MVS referente ao papel PETR4.

A. Fronteiras Eficientes

Para realização dos experimentos utilizando a variação do Modelo de Markowitz proposta, foram considerados, para comporem a carteira de investimentos, os seguintes papéis: AMBV4, GOLL4, ITUB4, PETR4 e VALE5.

Como é mostrado na Fig. 7, conforme o retorno aumenta o risco ao se investir também aumenta. Percebe-se que, até um certo nível de risco, os retornos da carteira utilizando os retornos previstos pelo predictor são maiores do que os retornos da carteira utilizando os retornos originais do conjunto de teste.




Figura 7. Experimentos realizados com diversos valores de retorno e risco.

Considerando um retorno (da carteira) desejado de 5%, o risco obtido utilizando os retornos originais de cada papel do conjunto de teste é de 0,3481%, enquanto que o risco obtido utilizando os retornos previstos pelo predictor é de 0,2824%. Logo, é uma vantagem o risco obtido pelo predictor ser menor, pois dá uma margem de segurança ao usuário (investidor). A alocação dos recursos com retorno desejado de 5% está representada na Tabela V.

TABELA V. ALOCAÇÃO DOS RECURSOS COM RETORNO DESEJADO DE 5%.

	Dados Originais	Dados Previstos
AMBEV	13%	20%
GOL	0%	0%
ITAUNIBANCO	87%	80%
PETROBRAS	0%	0%
VALE	0%	0%

Com um retorno desejado de 7,5%, o risco obtido utilizando dados originais é de 0,3529% e com o uso de dados previstos é de 0,2962%. E para um retorno desejado de 10%, o risco obtido com dados originais é de 0,4524% e com dados previstos é de 0,408%. Para os retornos desejados de 7,5% e 10%, a alocação dos recursos está representada nas Tabelas VI e VII.

TABELA VI. ALOCAÇÃO DOS RECURSOS COM RETORNO DESEJADO DE 7,5%.

	Dados Originais	Dados Previstos
AMBEV	25%	35%
GOL	8%	11%
ITAUNIBANCO	62%	54%
PETROBRAS	0%	0%
VALE	5%	0%

TABELA VII. ALOCAÇÃO DOS RECURSOS COM RETORNO DESEJADO DE 10%.

	Dados Originais	Dados Previstos
AMBEV	35%	44%
GOL	13%	16%
ITAUNIBANCO	36%	28%
PETROBRAS	0%	0%
VALE	16%	12%

B. Sistema Desenvolvido

Como resultado deste trabalho, foi desenvolvido um sistema (disponível em <http://github.com/andrecosta90/ISPS>) para a composição de carteiras de investimentos.

O sistema possui uma tela principal (Fig. 8 e Fig. 9). A opção Abrir possibilita ao usuário a escolha do arquivo de cotação históricas (estruturado conforme BM&FBOVESPA) desejado.

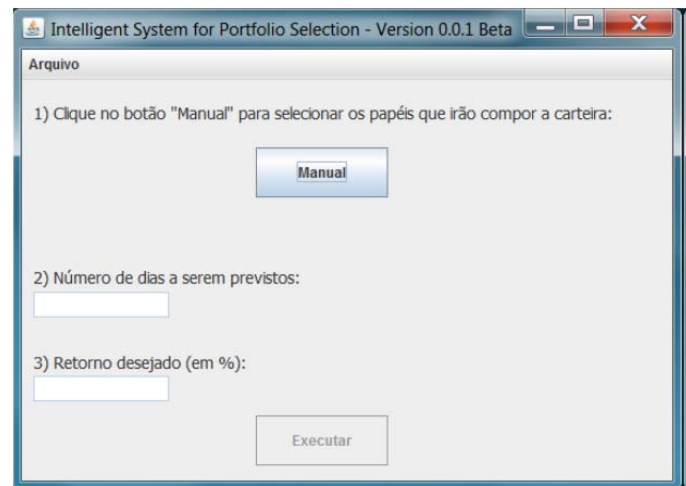


Figura 8. Tela principal do sistema desenvolvido.

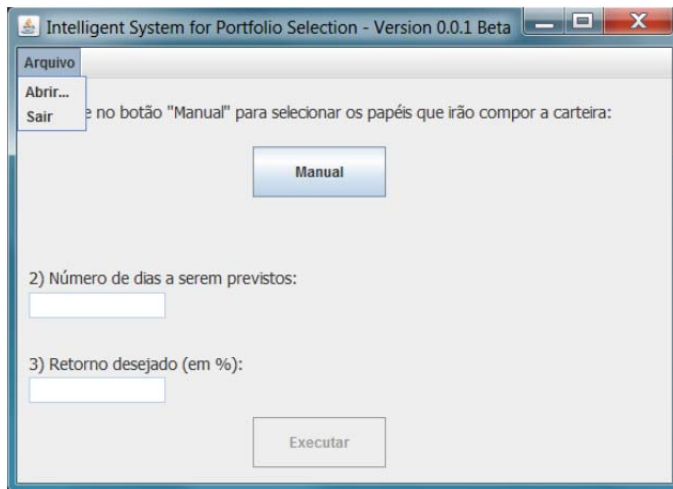


Figura 9. Opções: Abrir/Sair.

Ao clicar no botão *Manual*, surge a tela onde o usuário seleciona os papéis que devem compor a carteira (Fig. 10). A quantidade máxima de papéis permitida (cardinalidade) é 10. Ao concluir a seleção de papéis, o usuário deve clicar no botão *Pronto* (Fig. 11).

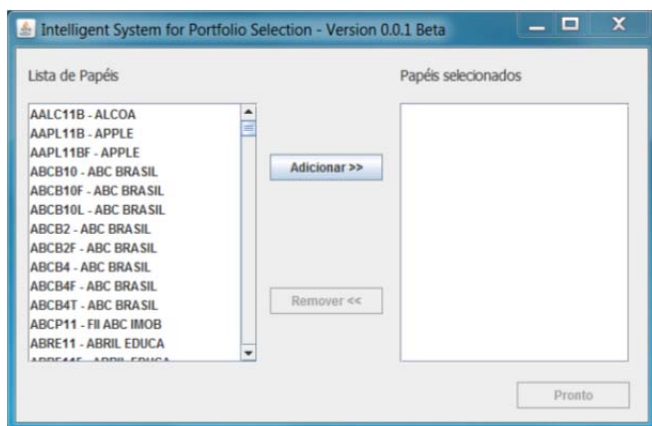


Figura 10. Tela de Seleção de Papéis.

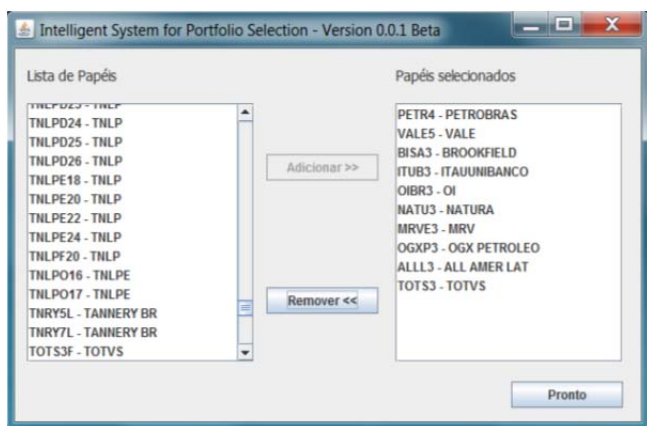


Figura 11. Papéis Selecionados.

Com os papéis selecionados, o usuário deve definir o número de dias a serem previstos e o retorno desejado (em

porcentagem). Após isso, o usuário deve clicar no botão *Executar* (Fig. 12). Ao clicar em executar, pode-se surgir:

- uma tela informando a maneira como se deve investir os recursos, ou seja, qual porcentagem alocar em cada papel que compõe a carteira (Fig. 13);
- ou uma mensagem informando que não foi possível encontrar uma solução. Neste caso, deve-se reduzir o retorno desejado ou modificar os papéis que compõem a carteira.

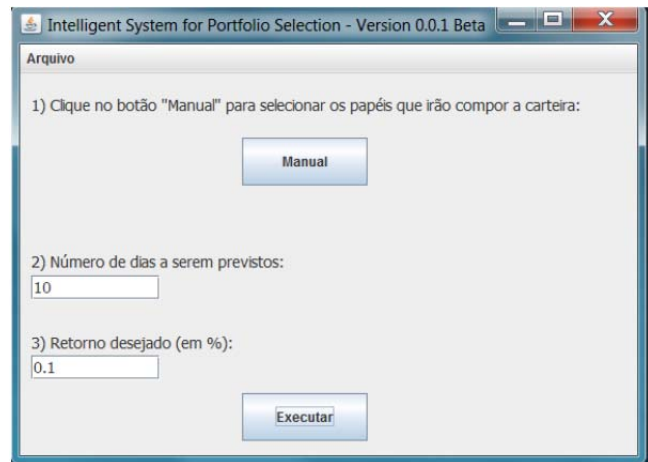


Figura 12. Definições do Usuário

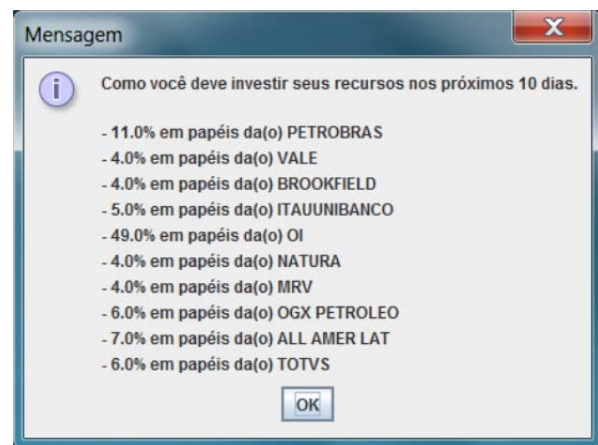


Figura 13. Tela informando a carteira ideal a se investir dada as definições impostas pelo usuário.

V. CONCLUSÃO E TRABALHOS FUTUROS

Este artigo apresentou uma variação do Modelo de Markowitz, onde foi utilizada a técnica MVS, em vez de técnicas estatísticas, para a previsão dos preços de fechamento futuros. Sua grande contribuição é o sistema inteligente desenvolvido que poderá vir a auxiliar investidores na escolha de ativos para a composição de uma carteira ótima de investimentos.

Apesar dos experimentos terem sido realizados considerando apenas os 71 papéis que compõem o índice Bovespa (IBOVESPA) e o período de um ano (de Janeiro a Dezembro de 2012), o sistema desenvolvido possibilita ao usuário inserir um período maior e, também, com mais papéis,

desde que o arquivo de dados esteja no formato da BM&FBOVESPA.

No presente artigo, tentou-se abstrair ao máximo do usuário o uso da técnica MVS. Para trabalhos futuros, seria interessante criar um módulo avançado, onde o usuário possa lidar com demais técnicas de Inteligência Computacional, definindo seus próprios parâmetros. Outras sugestões:

- adicionar funcionalidades ao sistema desenvolvido como, por exemplo, indicar papéis ao investidor, utilizando o índice *Sharpe*;
- melhorar a interface e o código do sistema desenvolvido;
- utilizar meta-heurísticas como *Particle Swarm Optimization* (PSO) ou *Simulated Annealing* para resolução do problema formulado por Markowitz.

REFERÊNCIAS

- [1] E. F. Brigham and M. C. Ehrhardt. *Financial Management: Theory & Practice*. South-Western College Pub; 13th edition, 2010.
- [2] H. Markowitz. Portfolio selection. *The Journal of Finance*, 7(1):77–91, 1952.
- [3] T. A. Silva. *Estudo Experimental de Técnicas para Otimização de Carteiras*. Dissertação de Mestrado - Departamento de Informática, Pontifícia Universidade Católica do Rio de Janeiro, 2010.
- [4] F. D. de Freitas, A. F. de Souza, F. J. N. Gomes, and A. R. de Almeida. Portfolio selection with predicted returns using neural networks. *IASTED International Conference on Artificial Intelligence and Applications*, 2002.
- [5] V. N. Vapnik and A. Y. Chervonenkis. On the uniform convergence of relative frequencies of events to their probabilities. *Theory of Probability and its Applications*, 16(2):264–280, 1971.
- [6] C. Cortes and V. Vapnik. Support-vector networks. *Machine Learning, Vol 20*, pages 273 – 297, 1995. Kluwer Academic Publishers Hingham, MA, USA.
- [7] V. N. Vapnik. *The nature of statistical learning theory*. Springer-Verlag New York, Inc., New York, NY, USA, 1995.
- [8] E. J. Elton, M. J. Gruber, S. J. Brown, and W. N. Goetzmann. *Modern Portfolio theory and Investment Analysis*. John Wiley & Sons, Inc., 8 edition, 2010.
- [9] C. W. Hsu, C. C. Chang, and C. J. Lin. A practical guide to support vector classification. *Department of Computer Science, National Taiwan University, Taipei 106, Taiwan*, pages 1–16, 2010.



André Hermenegildo Costa Silva é Bacharel em Sistemas de Informação pela Universidade Federal de Lavras (2013). Atualmente está cursando mestrado em Ciência da Computação pela Universidade Federal de Minas Gerais. Tem experiência na área de Ciência da Computação, com ênfase em Algoritmos, Estruturas de Dados e Inteligência Computacional. Tem interesse nos seguintes temas:

Aprendizado de Máquina, Redes Neurais Artificiais, Support Vector Machines, Mineração de Dados e Big Data.



Wilian Soares Lacerda obteve, em 2006, seu título de doutor em Engenharia Elétrica pela Universidade Federal de Minas Gerais. É mestre (1994) e graduado (1991) pela mesma universidade. Atualmente é professor associado da Universidade Federal de Lavras do Departamento de Ciência da Computação onde leciona disciplinas a nível de

graduação e pós-graduação. Desenvolve pesquisa na área de Inteligência Computacional, atuando principalmente nos seguintes temas: Redes Neurais Artificiais, Sistemas Fuzzy, e Computação Evolutiva. Desenvolve protótipos de sistemas embarcados para aplicações específicas utilizando: microcontroladores, hardware reconfigurável (FPGA), sensores e atuadores diversos.